

Materia: Redes Neuronales	Código: 25.63
Créditos: 3	Carga horaria total: 51
Departamento: Sistemas Digitales y Datos	Año: 2026
Carrera de: Ingeniería Electrónica / Ingeniería Civil	
Fecha última actualización: 29/6/2026 19:32:59	

➤ Carga horaria:

51	Horas totales
30	hs. teóricas
21	hs. prácticas
	hs. de laboratorio

3	Horas semanales
3	hs. presencial
	hs. a distancia

➤ Contenidos mínimos:

Introducción a Redes Neuronales - Modelos Generativos vs Discriminativos - Perceptrón MultiCapa - Optimización - Backpropagation - Regularización - Redes Neuronales Convolucionales - Redes Neuronales Recurrentes - Mecanismo de Atención.

➤ Presentación de la materia:

El curso tiene como propósito que el estudiante adquiera una comprensión sólida de los fundamentos del aprendizaje profundo desde una perspectiva ingenieril-aplicada, integrando los principios conceptuales, los mecanismos de entrenamiento y las arquitecturas neuronales troncales utilizadas en problemas de clasificación, regresión, visión por computadora y modelado secuencial básico.

➤ Objetivos de aprendizaje:

- Comprender los fundamentos teóricos y prácticos de las redes neuronales dentro del aprendizaje automático.
- Implementar arquitecturas neuronales densas, convolucionales y recurrentes básicas utilizando herramientas actuales.

- Entrenar, evaluar y comparar modelos mediante funciones de pérdida, métricas y técnicas de validación adecuadas.
- Aplicar estrategias de regularización, selección de hiperparámetros y seguimiento de experimentos.

➤ Contenidos:

Título	Descripción
Introducción, Modelos Generativos y Discriminativos, Probabilidad y Setup	Presentación general. Entorno de trabajo: Python, PyTorch, notebooks y estructura experimental. Panorama del aprendizaje profundo dentro del aprendizaje automático. Modelos generativos vs. discriminativos. Repaso breve de probabilidad, probabilidad condicional, regla de Bayes y likelihood. Relación entre salidas probabilísticas y funciones de pérdida.
Perceptrón Multicapa y Funciones de Activación	Perceptrón y limitaciones de modelos lineales. Perceptrón multicapa. Capas densas y representación matricial. Funciones de activación: sigmoid, tanh, ReLU y variantes. Implementación básica en PyTorch.
Forward Propagation y Backpropagation	Propagación hacia adelante. Cálculo de salidas intermedias y composición de capas. Retropropagación del error. Intuición de gradientes y regla de la cadena aplicada. Diferenciación automática en PyTorch.
Funciones de Pérdida, Métricas y Evaluación	Funciones de pérdida para clasificación y regresión. Cross-Entropy, MSE y variantes. Métricas: Exactitud, Precisión, Exhaustividad, F1, ROC/AUC y error cuadrático. Conjuntos de entrenamiento, validación y prueba. Interpretación de métricas y evaluación del desempeño.
Optimización y Entrenamiento	Descenso por gradiente. Mini-batch gradient descent. Optimizadores: SGD, Momentum y Adam. Learning rate y sensibilidad al entrenamiento. Curvas de aprendizaje. Comparación experimental de optimizadores.
Regularización y Búsqueda de Hiperparámetros	Overfitting y underfitting. Regularización L1/L2 y weight decay. Dropout y early stopping. Selección de hiperparámetros. Grid search y random search. Introducción a Optuna para búsqueda básica de configuraciones.
Inicialización, Batch Normalization y Buenas Prácticas	Inicialización de pesos. Xavier y He initialization. Batch normalization. Estabilidad numérica y convergencia. Buenas prácticas de entrenamiento. Diagnóstico de fallas frecuentes en modelos neuronales.
Redes Profundas	Diseño de arquitecturas profundas para clasificación y regresión. Cantidad de capas, ancho de

Aplicadas	red y capacidad de representación. Análisis de sesgo-varianza en modelos neuronales. Implementación y comparación de configuraciones. Presentación del TP1/TP2 integrados al trabajo experimental.
Redes Convolucionales: Fundamentos	Motivación de las CNN en visión por computadora. Convolución discreta. Kernels, stride, padding y receptive field. Pooling y reducción espacial. Extracción jerárquica de características. Comparación entre MLP y CNN para imágenes.
CNN para Clasificación de Imágenes	Arquitectura básica de una CNN. Clasificación supervisada de imágenes. Funciones de pérdida y métricas para visión. Data augmentation introductorio. Entrenamiento y evaluación en datasets de imágenes.
Arquitecturas Convolucionales y Transfer Learning	Arquitecturas clásicas: LeNet, AlexNet, VGG y ResNet. Comparación conceptual entre arquitecturas. Transfer learning. Fine-tuning básico. Aplicación práctica sobre modelos preentrenados.
Tracking de Experimentos y Análisis Experimental	Trazabilidad y reproducibilidad básica. Registro de hiperparámetros, métricas y artefactos. Uso introductorio de MLflow para seguimiento de corridas. Comparación experimental de modelos. Análisis de resultados y justificación de decisiones de diseño.
Modelado Secuencial con Redes Recurrentes	Introducción a datos secuenciales. RNN: estructura, propagación temporal y limitaciones. LSTM y GRU: arquitectura y diferencias. Aplicaciones básicas many-to-one y many-to-many. Implementación introductoria en PyTorch.
Modelado Secuencial con Mecanismos de Atención	Introducción a mecanismos de attention - Self Attention

➤ Estrategias de enseñanza:

En las clases teóricas, el alumno tomará contacto con conocimientos fundamentales de las redes neuronales así como metodológico con respecto al entrenamiento de modelos. Algunas clases profundizarán en modelos y herramientas de aplicación particulares y otras harán hincapié en la metodología de resolución.

En las clases prácticas se mostrarán problemas de referencia en los que se mostrarán la combinación de metodologías de trabajo en conjunto con herramientas o modelos relacionados a la resolución de estos problemas de referencia.

Los Trabajos Prácticos consisten en plantear un problema que integre varias clases teórico-prácticas, en los que se evaluará la validez de los modelos propuestos por el alumno además de una correcta metodología de entrenamiento, validación, evaluación y comparación de modelos.

➤ Actividades:

Título	Descripción
TP1	Implementación de redes neuronales feedforward para clasificación y/o regresión. - Modalidad: Práctica. Deben implementar un código en python que implementa la consigna. - Se dará 2 semanas a los alumnos para que hagan la implementación y utilicen los espacios de clase para realizar consultas. - Propuesta: 1 o 2 alumnos por equipo. - Metodología, seguimiento y calificación: Se establece una consigna de aplicación para que apliquen los conocimientos vistos en clase. Dentro de la consigna hay puntos calificables y la nota del trabajo se obtiene a partir de la cantidad de los puntos realizados correctamente. Rol docente: apoyo durante las semanas de desarrollo del TP. Proposición de mejoras.
TP2	Optimización, regularización, búsqueda de hiperparámetros y comparación de configuraciones. - Modalidad: Práctica. Deben implementar un código en python que implementa la consigna. - Se dará 2 semanas a los alumnos para que hagan la implementación y utilicen los espacios de clase para realizar consultas. - Propuesta: 1 o 2 alumnos por equipo. - Metodología, seguimiento y calificación: Se establece una consigna de aplicación para que apliquen los conocimientos vistos en clase. Dentro de la consigna hay puntos calificables y la nota del trabajo se obtiene a partir de la cantidad de los puntos realizados correctamente. Rol docente: apoyo durante las semanas de desarrollo del TP. Proposición de mejoras.
TP3	Clasificación de imágenes mediante redes convolucionales. - Modalidad: Práctica. Deben implementar un código en python que implementa la consigna. - Se dará 2 semanas a los alumnos para que hagan la implementación y utilicen los espacios de

	clase para realizar consultas. - Propuesta: 1 o 2 alumnos por equipo. - Metodología, seguimiento y calificación: Se establece una consigna de aplicación para que apliquen los conocimientos vistos en clase. Dentro de la consigna hay puntos calificables y la nota del trabajo se obtiene a partir de la cantidad de los puntos realizados correctamente. Rol docente: apoyo durante las semanas de desarrollo del TP. Proposición de mejoras.
TP4	Introducción al modelado secuencial con RNN, LSTM o GRU. - Modalidad: Práctica. Deben implementar un código en python que implementa la consigna. - Se dará 2 semanas a los alumnos para que hagan la implementación y utilicen los espacios de clase para realizar consultas. - Propuesta: 1 o 2 alumnos por equipo. - Metodología, seguimiento y calificación: Se establece una consigna de aplicación para que apliquen los conocimientos vistos en clase. Dentro de la consigna hay puntos calificables y la nota del trabajo se obtiene a partir de la cantidad de los puntos realizados correctamente. Rol docente: apoyo durante las semanas de desarrollo del TP. Proposición de mejoras.

➤ Recursos didácticos:

Acceso a GPU (Google Colab / laboratorio local).
 Python 3.10+, PyTorch, NumPy, pandas, matplotlib, scikit-learn.
 Herramientas auxiliares para seguimiento de experimentos y búsqueda de hiperparámetros: MLflow y Optuna.
 Conectividad a internet y repositorio GitHub para entrega de jupyter notebooks.

➤ Modalidad de evaluación y aprobación:

Modalidad de evaluación:

La nota final se calculará según la siguiente ponderación:

TP1: 25 %

TP2: 25 %

TP3: 25 %

TP4: 15 %

Participación y asistencia: 10 %

Requisitos de aprobación:

Promedio de cursada superior a 6.

Tres de los cuatro TPs aprobados.

➤ Bibliografía obligatoria:

N°	Descripción
1	Goodfellow, I., Bengio, Y. & Courville, A. (2016). Deep Learning.
2	Chollet, F. (2021). Deep Learning with Python.
3	Nielsen, M. (2015). Neural Networks and Deep Learning.
4	
5	
6	

➤ **Bibliografía complementaria:**

N°	Descripción
1	Bishop, C. (2006). Pattern Recognition and Machine Learning.
2	LeCun, Y., Bengio, Y. & Hinton, G. (2015). Deep Learning.
3	Krizhevsky, A., Sutskever, I. & Hinton, G. (2012). ImageNet Classification with Deep Convolutional Neural Networks
4	He, K. et al. (2016). Deep Residual Learning for Image Recognition.
5	Cho, K. et al. (2014). Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation.
6	Vaswani, A. et al. (2017). Attention Is All You Need