

Materia: Big Data	Código: 72.80
Créditos: 3	Carga horaria total: 51
Departamento: Sistemas Digitales y Datos	Año: 2025
Carrera de:	
Fecha última actualización: 12/8/2025 10:37:24	

➤ Carga horaria:

51	Horas totales
33	hs. teóricas
18	hs. prácticas
0	hs. de laboratorio

3	Horas semanales
3	hs. presencial
0	hs. a distancia

➤ Contenidos mínimos:

Sistemas de archivos distribuidos: estructura y funcionamiento. Clústeres de almacenamiento distribuido. Consulta y modelado de bases de datos NoSQL. Implementación de algoritmos de procesamiento distribuido y paralelo. Modelo de programación MapReduce. Streaming y análisis de datos en tiempo real.

➤ Presentación de la materia:

En un mundo cada vez más impulsado por datos, la capacidad de gestionar y analizar eficientemente grandes volúmenes de datos se ha convertido en un factor crítico para el éxito de las organizaciones. Empresas de diversos sectores, como finanzas, salud, comercio electrónico, telecomunicaciones y marketing, requieren profesionales capacitados en Big Data para tomar decisiones informadas basadas en datos y obtener una ventaja competitiva.

En ese sentido, para los profesionales que posean habilidades en Big Data existe una ventaja competitiva significativa en el mercado laboral actual y futuro. El dominio de estas tecnologías abre las puertas a oportunidades profesionales emocionantes, como científico de datos, ingeniero de Big Data, analista de datos, arquitecto de datos o consultor de Big Data.

El curso de Tecnologías de Big Data está diseñado para proporcionar a los estudiantes los conocimientos y habilidades necesarios para enfrentar los desafíos del análisis y procesamiento de grandes volúmenes de datos en el entorno actual.

Este curso se centra en desarrollar competencias tanto teóricas como prácticas en el ámbito del Big Data. Los

estudiantes aprenderán los fundamentos conceptuales de Big Data, comprendiendo la importancia y los desafíos asociados con el procesamiento y análisis de grandes volúmenes de datos. Además, adquirirán habilidades prácticas en el uso de tecnologías y herramientas populares de Big Data, como sistemas de archivos distribuidos, bases de datos NoSQL, procesamiento en tiempo real, análisis de datos y minería de datos. Los graduados de este curso serán valorados en el entorno empresarial debido a su capacidad para abordar problemas complejos de datos, extraer información valiosa y ayudar a las organizaciones a tomar decisiones estratégicas basadas en evidencia.

En resumen, el propósito de este curso de Big Data es capacitar a los estudiantes en las competencias teóricas y prácticas necesarias para enfrentar los desafíos del procesamiento y análisis de grandes volúmenes de datos. Al finalizar el curso, los estudiantes estarán preparados para aprovechar las oportunidades profesionales en el campo del Big Data, aportando valor a las organizaciones y siendo partícipes en el avance de la sociedad impulsada por datos.

➤ Objetivos de aprendizaje:

Al finalizar el curso los alumnos deberán:

- Comprender las arquitecturas y tecnologías utilizadas para almacenar, procesar y analizar grandes volúmenes de datos.
- Conocer el funcionamiento de los sistemas de archivos distribuidos como Hadoop Distributed File System (HDFS); entender su estructura y funcionamiento.
- Saber configurar y administrar clústeres de almacenamiento distribuido para el manejo eficiente de grandes conjuntos de datos.
- Dominar la sintaxis de consulta y el modelado de datos en bases de datos NoSQL.
- Saber seleccionar la base de datos NoSQL adecuada según los requisitos de la aplicación.
- Utilizar frameworks y herramientas como Apache Hadoop y Apache Spark para implementar algoritmos de procesamiento distribuido y paralelo.
- Dominar el modelo de programación MapReduce y saber cómo diseñar y desarrollar programas MapReduce utilizando lenguajes como Java o Python.
- Utilizar herramientas y plataformas como Apache Kafka y Apache Spark Streaming para procesar y analizar datos en tiempo real.
- Aplicar los conocimientos adquiridos en casos de uso reales de analítica de Big Data utilizando bibliotecas de Hadoop y Spark.
- Implementar técnicas de cifrado, enmascaramiento y anonimización de datos para garantizar la privacidad y confidencialidad de la información sensible en entornos de Big Data.

➤ Contenidos:

Título	Descripción
Unidad 1: Bienvenida al curso de Tecnologías de Big Data	■ Objetivo del curso y repaso de requisitos previos ■ Introducción a las tecnologías para el procesamiento de Big Data. ■ Big Data y el mundo empresarial.
Unidad 2: Introducción a Big Data	■ Definición y características de Big Data ■ Tipos de datos y fuentes de datos ■ Desafíos y oportunidades en el análisis de Big Data

	■ Casos de uso de Big Data en diferentes industrias
Unidad 3: Almacenamiento y gestión de Big Data	■ Sistemas de archivos distribuidos ■ Bases de datos NoSQL ■ Almacenamiento en la nube para Big Data ■ Arquitecturas de almacenamiento escalables y tolerantes a fallos
Unidad 4: Procesamiento de Big Data	■ Procesamiento distribuido y paralelo ■ MapReduce y frameworks similares ■ Procesamiento en tiempo real ■ Uso de lenguajes y herramientas de programación para Big Data
Unidad 5: Análisis y minería de datos	■ Técnicas de análisis de datos ■ Minería de datos y descubrimiento de patrones ■ Aprendizaje automático aplicado a Big Data ■ Visualización de datos masivos
Unidad 6: Procesamiento de datos en tiempo real	■ Arquitecturas de procesamiento en tiempo real, como Lambda Architecture y Kappa Architecture ■ Streaming de datos y procesamiento en tiempo real con Apache Kafka ■ Procesamiento de datos en streaming con Apache Spark Streaming
Unidad 7: Análisis de texto y procesamiento del lenguaje natural	■ Fundamentos del procesamiento del lenguaje natural (PLN) ■ Extracción de características de texto y análisis de sentimientos ■ Procesamiento de texto a gran escala con Apache Hadoop y Apache Spark
Unidad 8: Seguridad y privacidad en Big Data	■ Desafíos de seguridad en el entorno de Big Data ■ Técnicas de cifrado y enmascaramiento de datos ■ Marco legal y ético para el manejo de datos sensibles

➤ Estrategias de enseñanza:

Las clases son virtuales sincrónicas. En las clases teóricas se trabajará con material en diapositivas donde se expondrán los conceptos de la materia.

Para los TPs se trabajará con plataformas virtuales donde se podrán preparar y resolver los ejercicios.

Por otra parte, en el aula virtual (campus) se pondrán a disposición los siguientes materiales:

- Actividades de clases y demostraciones
- Ejercicios de laboratorio
- Artículos, conferencias y videos relevantes
- Soluciones ejemplo

➤ Actividades:

Título	Descripción
Trabajo Práctico 1	Configurar un entorno de Google Colab con PySpark y cargar un dataset simple.
Trabajo Práctico 2	Crear y manipular un DataFrame en PySpark usando Google Colab.
Trabajo Práctico 3	Leer y escribir datos en formatos como CSV y Parquet
Trabajo Práctico 4	Realizar consultas SQL sobre un dataset de gran tamaño
Trabajo Práctico 5	Simulación de procesamiento en tiempo real con PySpark Streaming. Semanas
Discusión en clase 1	Regulaciones y su impacto en el manejo de datos masivos
Discusión en clase 2	El impacto de la IA y Big Data en la sociedad

➤ Recursos didácticos:

Presentaciones de los temas de la materia.

Prácticas a desarrollar por los alumnos en sus computadoras.

Discusión de las prácticas y de su resolución.

➤ Modalidad de evaluación y aprobación:

Modalidad de evaluación:

La nota de cursada será idéntica a la nota del examen parcial que se toma al final del curso.

Al finalizar el curso los alumnos presentarán grupalmente un Proyecto Final propuesto. Este proyecto se presenta en forma grupal pero cada alumno debe ser capaz de explicarlo. La nota obtenida de este modo equivale a la nota del final de la materia.

Requisitos de aprobación:

Para aprobar la cursada los alumnos deberán obtener un mínimo de 4 (cuatro puntos) en el parcial y en el Proyecto Final.

La nota definitiva resultará, como es habitual, del promedio entre la nota de cursada y la del final (Proyecto Final).

➤ Bibliografía obligatoria:

N°	Descripción
1	Anil Maheshwari (2017). Big Data Essentials. Routledge, Taylor & Francis Group
2	White, T. (2015). Hadoop: The definitive guide (4th ed.). O'Reilly
3	Bill Chambers, Matei Zaharia (2018). Spark: The Definitive Guide. O'Reilly
4	
5	
6	

➤ Bibliografía complementaria:

N°	Descripción
1	Dean, J., & Ghemawat, S. (2008). MapReduce: Simplified data processing on large clusters. Communications of the ACM, 51(1), 107-113

2	Vouk, M. A. (2008). Cloud computing: Issues, research and implementations. Journal of Computing and Information Technology, 16(4), 235-246
3	Jules Damji, Brooke Wenig, Tathagata Das, Denny Lee. Learning Spark: Lightning-Fast Data Analytics. O'Reilly
4	Sandy Ryza, Uri Laserson, Sean Owen, Josh Wills (2015). Advanced Analytics with Spark. O'Reilly
5	
6	