

Materia: Análisis Predictivo	Código: 82.05
Créditos: 6	Carga horaria total: 102
Departamento: Economía, Sociedad y Negocios	Año: 2026
Carrera de:	
Fecha última actualización: 6/5/2026 12:56:54	

➤ Carga horaria:

102	Horas totales
52	hs. teóricas
28	hs. prácticas
22	hs. de laboratorio

6	Horas semanales
4	hs. presencial
2	hs. a distancia

➤ Contenidos mínimos:

Modelos estadísticos para extracción de patrones y relaciones desconocidos en grandes volúmenes de datos. Predicción de tendencias y comportamientos futuros. Modelos estadísticos basados en reglas de correlación, árboles de decisión y regresión estadística, entre otras técnicas. Implementación de modelos utilizando lenguaje R y herramientas comerciales de análisis predictivo.

➤ Presentación de la materia:

Conocimientos previos:

La materia requiere como principales conocimientos previos entendimiento de estadística aplicada, matemáticas y también manejo de bases de datos a nivel descriptivos con herramientas de código abierto (Python y R principalmente).

El propósito general de la materia:

Introducir a los alumnos en el análisis de modelos predictivos

Se espera que los alumnos al finalizar la materia tengan la capacidad de seleccionar un conjunto de información que les sea útil para sus requerimientos, lo puedan procesar y seleccionar un modelo que se ajuste a las necesidades.

En el actual estado del arte de la materia la mayoría de los modelos se enmarcan dentro de la gran familia del aprendizaje de máquina (Machine Learning). Sin embargo, para lograr una correcta aplicación de estos modelos resulta fundamental el correcto ajuste de los datos (data wrangling) y la comprensión de los mismos.

> Objetivos de aprendizaje:

En función de lo expresado anteriormente, se espera que en esta materia los alumnos logren:

- Reconocer la gran potencialidad que el uso de datos tiene en la actualidad.
- Adquirir herramientas para modelar, estimar y predecir el comportamiento de las variables cualquiera sea su origen.
- Elaborar una propuesta mejorada de uso de datos y predicción de comportamiento
- Desarrollar habilidades para evaluar y medir la precisión de los modelos predictivos

> Contenidos:

Título	Descripción
- Unidad 1: Análisis de Bases de Datos	Análisis de outlier, missing data, dataset balanceados/desbalanceados
- Unidad 2: Tratamiento de Bases de Datos	Normalización, standarización, tratamientos de variables cualitativas.
- Unidad 3: Modelos de clusterización	k-mean, KNN, UMAP, Bayes y otros modelos de clusterización.
- Unidad 4: Modelos predictivos	Regresiones (multi y univariantes), Random Forest, XGBoost, SVM y Redes Neuronales.
- Unidad 5: Evaluación de Modelos	Entendimiento y desarrollo de principales indicadores de evaluación: F1, ACC, Sensibilidad, Especificidad y curva AUROC.

➤ Estrategias de enseñanza:

La propuesta metodológica se centra en clases teórico prácticas. Se dará prioridad a la exposición del docente con instancias de participación de los alumnos. Además, se realizan trabajos prácticos en pequeños grupos y trabajos en el espacio de laboratorio.

El acompañamiento docente en la cursada para posibilitar el alcance de los objetivos se realiza aprovechando todos los canales posibles de comunicación tanto los feedback de cada entrega de los alumnos (detallado en Modalidad de Evaluación) con el objetivo de corregir y reforzar conceptos no asimilados en clase. Asimismo, tenemos abierta la pizarra de blackboard para el intercambio de material teórico y debate sobre problemas prácticos. Por último, incorporamos en espacio al finalizar cada clase una revisión de espacio y preguntar para asentar los conocimientos dados.

En caso de tener clases virtuales se contabilizan como hora de cursada. Las mismas, serán priorizadas para los espacios de "Talleres prácticos de Bussines Case" (detallado en la sección de Actividades) y ciertas clases donde el aprovechamiento de la virtualidad ayuda a la experiencia de clase como en los casos de clases de mayor cantidad de laboratorio.

➤ Actividades:

Título	Descripción
A. Clases teórico prácticas	Dichas clases que representarán un 80% del las horas de cursada de la materia, constará de dos partes. La primera parte teórica, donde se repasarán los principales conceptos matemáticos y estadísticos La primera parte práctica (u horas de laboratorio), donde se ejecutan ejercicios prácticos para poner en practica lo enseñado de la sección teórica mediante el tratamiento de dataset y la corrida de los algoritmos mediante herramientas de código abierto (Python y R-Studio).
B. Taller práctico de Bussines Case	Dichas clases que representarán un 10% del las horas de cursada de la materia. Se invitan a referentes del negocio y de la industria de Machine Learning para exponer Bussines Case relacionado a los modelos y algoritmos presentados en clase.
C. Presentación de alumnos	Dichas clases que representarán un 10% del las horas de cursada de la materia. En estas clases, el objetivos es que alumnos realicen presentaciones de casos para poner en práctica los modelos desarrollados en clase

➤ Recursos didácticos:

En los encuentros presenciales se trabajará con pizarrón y proyector. En las reuniones virtuales el docente presenta el tema y los alumnos replican en sus propias computadoras. Se utilizarán los siguientes software: R, Python, Excel. En el aula virtual (campus) se pondrán a disposición los materiales de lectura (bibliografía, artículos, conferencias, videos, etc.), se habilitarán espacios donde cada alumno deberá subir sus TPs.

➤ Modalidad de evaluación y aprobación:

Modalidad de evaluación:

La modalidad de evaluación contará de dos instancias:

Examen 1. TRATAMIENTO DE DATASET, ANÁLISIS Y GRÁFICOS

Consigna:

1. Elegir o armar una base de datos con el objetivo de desarrollar un modelo predictivo. Analizar la posibilidad de actualizar la información en el futuro. Piense que si bien muchas bases vienen armadas, otras tantas las puede obtener por una API, haciendo scraping, o de alguna otra forma. Es importante que el caso de negocio sea interesante y orientado a la aplicación de un modelo predictivo.

Recuerde: Considere que para algunos casos 500 observaciones puede ser suficiente, en otros casos no. Es preferible (en principio) tomar todas las observaciones disponibles. Si bien no es un criterio absoluto, recomendamos que la base armada no tenga menos de 10 variables y un volumen de datos significativo (recomendable +1000).

2. Limpiar la base, revisar NA, outliers, etc.

3. Hacer un análisis exploratorio. Incluya los gráficos y estadísticas que crea necesarias.

4. ELABORAR UN PPT, donde se analice como un caso de estudio los datos empleando y apoyándose en herramientas estadísticas, distintos recursos gráficos y tecnologías. Se espera utilice el formato de presentación institucional del ITBA.

El día del examen deberá realizar una presentación con el PPT elaborado.

Nota: El PPT/PDF + Bases deben ser enviadas el mismo día de la presentación. Se espera que envíe por mail el link a un repositorio de GitHub o similar que contenga el código y la presentación en PPT o PDF, o bien el link a Github con el código y el link a google Slides o similar con la presentación. No envíe archivos por mail.

Aspectos a tener en cuenta:

Extensión: Entre 12-15 diapositivas.

Modalidad: Presentación en clase con rango de duración de 20-30 (min) aprox.

Estructura para la presentación:

- Explicar el objetivo (el problema que se busca resolver, qué variable target se utilizará para predecir, ya sea por regresión o clasificación).

- Presentación y Análisis de Datos: Apoyándose en herramientas estadísticas básicas para realizar el análisis (recomendable media, mediana, varianza, deciles, etc). Asimismo, explicar brevemente qué pasos técnicos se realizaron en caso de limpiar, agrupar, filtrar la información y con qué objetivo.

- Problematicar y Describir los Datos: Analizar tendencias, explicar qué problemas contiene la información, qué se puede hacer (y qué no) con la información (recomendable: analizando periodicidad, frecuencia de actualización, nivel de granularidad, ausencia de variables, etc.).

- Conclusiones e Insight: Analizando profundamente la información, explicar y exponer las principales conclusiones y qué posibles usos brinda dicha información.

Se espera que durante el examen pueda responder preguntas del tipo: ¿Por qué eligió ese dataset? ¿Qué variable espera predecir? ¿Qué variables estarán disponibles a la hora de hacer la predicción? ¿Cómo es el balance de clases (si se trata de un problema de clasificación)? ¿De dónde obtuvo los datos? ¿Por qué es interesante este dataset? ¿Qué es esa variable?

Excelencia: Si usted aspira a un trabajo sobresaliente puede pensar en incorporar variables que no estén inicialmente en el dataset pero que puedan resultar interesantes para la predicción. Incluso si eso le implica ponerse a scrapear datos de algún lado. También debería poner mucho énfasis en la presentación visual de los datos. Puede pensar en gráficos animados, o una presentación interactiva con dashboards. Será indispensable que tenga un excelente entendimiento de la base, y que el caso de negocio se pueda resolver con un modelo predictivo.

Examen 2. COMPETENCIA KAGGLE

Realizar una "submission" a la siguiente competencia de Kaggle con R^2 superior al 90%*

(*Nota: dicho porcentaje es orientativo y será definido en el taller o clases previas al examen)

<https://www.kaggle.com/competitions/analisis-predictivo-2023q1>

El día del examen se espera que presente un PPT donde la segunda diapositiva (después de la carátula) sea un print

screen del score obtenido. En las siguientes diapositivas deberá explayarse respecto a cómo hizo para obtener dicho score. Se recomienda que muestre el EDA que haya realizado, el trabajo necesario sobre la base, una selección de los mejores modelos que haya probado, el ajuste de hiperparámetros utilizado, etc.

El principal objetivo de la presentación es que usted demuestre que no logró ese score de casualidad, ni se lo copió, sino que realmente entiende el funcionamiento de lo que su código hace.

Se espera utilice el formato de presentación institucional del ITBA.

Nota: El PPT/PDF + código utilizado para obtener dicho score (en el lenguaje que prefiera utilizar: R, Python, etc.) serán entregados el mismo día de la presentación. Se espera que envíe por mail el link a un repositorio de GitHub o similar que contenga el código y la presentación en PPT o PDF, o bien el link a Github con el código y el link a google slides o similar con la presentación. No envíe archivos por mail.

El día del examen se espera que usted pueda responder preguntas del tipo: ¿Cómo hizo la selección de modelos? ¿Por qué usó ese hiperparámetro? ¿Cómo se podría mejorar el modelo?

Excelencia: Si usted aspira a un trabajo sobresaliente deberá tener de los mejores scores de la comisión. Deberá tener un excelente entendimiento de la base, del trabajo realizado, del algoritmo elegido y su superioridad respecto a otros posibles. Su presentación (tanto el PPT como la oral) deberá ser clara y precisa.

Consignas EXAMEN FINAL

Fechas: a confirmar

1- Elegir un dataset con una cantidad significativa de datos y variables (features), que sea plausible para generar modelos predictivos (ya sea regresión o clasificación). Idealmente se espera que este dataset sea el mismo del primer examen.

2- Incluir en la presentación una introducción que contenga los “Objetivos del trabajo” con una o dos hipótesis a corroborar o contrastar. Dicha hipótesis debe elaborarse en base a conocimientos previos, marco teórico o análisis exploratorio preliminar del dataset.

3- Desarrollar un EDA introductorio que incluya una descripción del dataset

Recomendable: Incluir cuántas variables contiene el dataset, outliers, missing data y gráficas histograma, mapa de correlación y explicación cualitativa, etc.

4- Aplicar los modelos que crea necesario, describiendo paso a paso su implementación, inconvenientes y resultados. Evaluar los modelos con métricas apropiadas.

Nota 1: Incluir en la descripción/análisis: como se realizó la limpieza y transformación de datos, partición del dataset, y todos los pasos antes y después de entrenar los modelos.

Nota 2: Es fundamental elegir métricas de evaluación apropiadas para el problema de predicción que se quiere resolver.

Nota 3: Es recomendable explicar qué metodología utilizó para el ajuste de hiperparámetros.

5- Elaborar un apartado final con todas las conclusiones y hallazgos obtenidos a partir del pto. 4; incluyendo un análisis comparativo entre los algoritmos empleados.

Aspectos a tener en cuenta:

A. Presentar en archivo formato PPT o PDF (Utilizando el template de ITBA), con una extensión recomendable de alrededor 20 páginas (es posible más, no menos).

B. En la entrega final se debe enviar post presentación: PPT/PDF, dataset trabajado (o una muestra en caso de ser muy grande) y scripts (en Python, R o similar) sobre donde se trabajaron los algoritmos/modelos. Se espera que envíe por mail el link a un repositorio de GitHub o similar que contenga el código y la presentación en PPT o PDF, o bien el link a Github con el código y el link a google slides o similar con la presentación. No envíe archivos por mail.

C. Todos los gráficos y resultados deben ser claros y tener un sentido para el desarrollo de la presentación (storytelling).

El día del examen usted deberá poder responder preguntas del tipo: ¿Qué transformaciones aplicó sobre los datos y por qué? ¿Cómo es el balance de clases y qué hizo al respecto (si se trata de un problema de clasificación)? ¿Por qué usó ese modelo de clasificación/regresión y no otro?

Excelencia: Si usted aspira a un trabajo sobresaliente, la presentación deberá ser precisa y clara. El modelo elegido deberá ser apropiado (luego de haber probado muchos posibles). Deberá responder con claridad las preguntas planteadas. El caso de negocio deberá resultar interesante y pertinente. Su comprensión de la base y de los modelos utilizados deberá ser elevada.

- Modalidad de evaluación

A lo largo de la materia la evaluación de los alumnos abarcará la dimensión del proceso y la del producto. Por un lado, se evaluará la participación de los alumnos en las actividades propuestas. Se espera que interactúen en forma

activa y comprometidamente con el/la docente y sus compañeros, y que cumplan con las tareas en tiempo y forma. Además, los alumnos deben rendir (con entrega de la presentación y explicación simultánea) dos Trabajos Prácticos/Trabajos prácticos de laboratorio y un Trabajo Práctico Final.

Con posterioridad, los alumnos recibirán una devolución escrita individual o grupal acerca de su desempeño.

Requisitos de aprobación:

- Aprobar con una nota de 4 (cuatro) puntos obtenida en cada uno de los trabajos prácticos parciales.
- Aprobar con un mínimo de 4 (cuatro) el trabajo práctico final.
- Contar con un porcentaje de asistencia para mantener la regularidad, que es de 75%.
- A su vez se considerará positivamente la participación activa en clase, y la elaboración de las actividades propuestas como ejercicios.

¿Cómo se calcula la nota de cursada?

Ejemplo 1: Para los alumnos que hayan aprobado los dos parciales sin recuperación, la nota de cursada final se obtendrá de la siguiente manera: $(P1 + P2) / 2$

Ejemplo 2: Para los alumnos que hayan aprobado uno de los parciales con recuperación, la nota final de cursada final se obtendrá de la siguiente manera: $((P1+R1) / 2 + P2) / 2$ o $(P1 + (P2+R2) / 2) / 2$

¿Cómo se redondea la nota de cursada?

La nota correspondiente a la cursada será redondeada según el siguiente criterio:

- Si la parte decimal es menor o igual que 0,25, se pasa al entero inmediatamente inferior.
- Si la parte decimal está comprendida entre 0,26 y 0,75, se deja como 0,50.
- Si es mayor a 0,75, la nota se lleva al entero superior más cercano.

➤ Bibliografía obligatoria:

N°	Descripción
1	Inteligencia Artificial: Lo que todo el mundo debe saber – Jerry Kaplan

➤ Bibliografía complementaria:

N°	Descripción
1	
2	
3	
4	
5	

6	
---	--