

Materia: Procesamiento del Lenguaje Natural	Código: 82.18
Créditos: 3	Carga horaria total: 51
Departamento: Economía, Sociedad y Negocios	Año: 2024
Carrera de: Licenciatura en Analítica Empresarial y Social / / Ingeniería en Informática	
Fecha última actualización: 9/12/2024 18:52:57	

➤ Carga horaria:

51	Horas totales
35	hs. teóricas
16	hs. prácticas
0	hs. de laboratorio

3	Horas semanales
3	hs. presencial
0	hs. a distancia

➤ Contenidos mínimos:

Introducción al NLP, Técnicas de procesamiento y preparación de textos, modelos de lenguaje, clasificación de textos, tecnologías para el procesamiento de lenguaje natural, aplicaciones típicas.

➤ Presentación de la materia:

Se trata de una materia electiva de la etapa final de las carreras de Ingeniería en Informática y la Licenciatura en Analítica Empresarial y Social. La materia ofrece herramientas fundamentales para comprender y desarrollar tecnologías innovadoras que permiten analizar, interpretar y utilizar eficientemente el vasto y complejo mundo del lenguaje humano en la era digital.

La materia se propone introducir a los alumnos en el campo del Procesamiento del Lenguaje Natural (PLN). Las técnicas de NLP destacan entre los algoritmos de procesamiento de datos no estructurados por sus posibilidades de aplicación en el ámbito académico, empresarial y social. Con el aumento del volumen de información de texto disponible, estas herramientas son muy valiosas para cualquier profesional dedicado al análisis de datos.

Se espera que los alumnos cuenten con conocimientos previos básicos de inglés, lenguaje Python, estadística y probabilidad, y manejo de bases de datos. Asimismo se recomienda enfáticamente haber cursado Análisis Predictivo y/o Sistemas de Inteligencia Artificial y/o Aprendizaje Automático antes de cursar esta materia.

➤ Objetivos de aprendizaje:

Se espera que en esta materia los alumnos logren:

- Tomar conciencia de los distintos tipos de datos de texto disponibles y su posible aprovechamiento
- Adquirir herramientas para analizar, procesar y extraer información pertinente de estos textos.
- Desarrollar la capacidad de formular preguntas relevantes que se puedan abordar con técnicas de PLN
- Aprender una base de conocimiento para profundizar, con un espíritu crítico, en temas avanzados y en nuevas herramientas por su cuenta

➤ Contenidos:

Título	Descripción
Obtención y normalización de texto	Normalización y análisis exploratorio de texto. Tokenización.
Embeddings y asociaciones semánticas	Pointwise mutual information. Word embeddings estáticos. Medición de similitud semántica. Aplicaciones en ciencias sociales computacionales.
Introducción a redes neuronales	Modelos de lenguaje ngram. Redes feedforward. Entrenamiento de redes neuronales. Intro a Pytorch
Topic Modelling	Clustering. Latent Dirichlet Allocation. Otros modelos de soft clustering. Aplicaciones
Language Models	Perplexity. Window-based FFNNs con embeddings. Modelos de N-gramas
Transformers	Self-attention, Transformer block, Multihead attention, Position embeddings, Entrenamiento paralelizable
Transfer Learning y pretraining	Paradigma pretrain LM (self-supervised learning) + fine-tune, BERT, Embeddings contextualizados, Evaluación de LLMs, Introducción a in-context learning con modelos multitask/generalistas como GPT3> (zero-few shot vs fine-tuning)
Encoder-Decoder NNs y Machine Translation	Arquitectura encoder-decoder, Evaluación de MT: humana vs automática.
Sesgos y NLP	Sesgos de representación en sistemas de NLP, Estudio de sesgos en los textos (computational

	social science)
--	-----------------

➤ Estrategias de enseñanza:

El curso constará de clases sincrónicas y del acompañamiento a un trabajo práctico desarrollado por los estudiantes en forma asincrónica. Se hará especial énfasis en la aplicación de las técnicas presentadas en lenguaje Python. La modalidad de cursada es presencial, con algunos encuentros virtuales. En las clases se presentarán tanto fundamentos teóricos como ejemplos de aplicaciones prácticas, y se pondrá especial énfasis en la participación de los estudiantes.

➤ Actividades:

Título	Descripción
Presentación de temas	Se presenta teóricamente un tema haciendo especial hincapié en su utilidad práctica, es decir, qué tipo de problemas este viene a resolver
Ejemplificación en Python	Luego de presentado el tema teóricamente el mismo puede ser puesto en práctica con un ejercicio o un caso de la vida real en código Python. Los alumnos pueden seguir el código o bien replicar el mismo en sus propias computadoras.

➤ Recursos didácticos:

En los encuentros presenciales se trabajará con pizarrón y proyector. Se utilizarán los siguientes software: Python (ya sea sobre plataforma Anaconda o Google Colab). En el aula virtual (campus) se pondrán a disposición los materiales de lectura (bibliografía, artículos, conferencias, videos, etc.), se habilitarán espacios donde cada alumno deberá subir sus TPs. Se recomienda el uso de Github para el control de versionado y entrega de trabajos.

Durante las clases se presentarán las demostraciones teóricas de los algoritmos y modelos abordados. También se presentarán casos de uso reales ya sea de aplicaciones en el ámbito académico o profesional. Se espera que al ir completando el trabajo práctico durante la cursada de la materia (ver las distintas etapas en la sección de modalidad de evaluación) los alumnos puedan ir poniendo en práctica los contenidos teóricos que se presenten en clase.

➤ Modalidad de evaluación y aprobación:

Modalidad de evaluación:

La materia tiene dos instancias de evaluación: un trabajo práctico orientado a aplicar contenidos de la materia a un problema real, y un examen escrito. La nota de cursada equivale a la nota obtenida en la entrega final del trabajo práctico. La nota del final equivale a la nota obtenida en el examen escrito.

El trabajo práctico se propone como trabajo en grupos. Se recomienda la interacción entre las carreras de Ingeniería en Informática y la Licenciatura en Ciencia de Datos. El objetivo es aplicar los contenidos de la materia a un problema real.

El trabajo práctico requiere dos entregas parciales y una entrega final.

Para la primera entrega se espera que cada grupo:

Defina el objetivo general del trabajo (el problema a resolver o pregunta a responder)

Defina los datos necesarios para lograr el objetivo

Haga un análisis exploratorio de los datos con las técnicas vistas en la primera parte del curso

Defina posibles análisis o experimentos a realizar para lograr el objetivo

Para la segunda entrega cada grupo deberá agregar al informe una sección de “Experimentos”, donde se debe detallar:

Experimentos o análisis específicos que se van hacer, incluyendo su justificación en relación al objetivo o pregunta.

Es decir, para cada experimento: ¿qué voy hacer? ¿cómo lo voy a hacer? ¿por qué lo voy a hacer?

Avances en caso de haberlos (no es requisito)

Para la entrega final se espera que cada grupo presente los resultados obtenidos. No necesariamente los métodos y resultados deben alcanzar los estándares del Estado del Arte, pero sí deben estar implementados y evaluados correctamente, en línea con lo planteado a lo largo del curso. Se espera una participación equitativa de todos los integrantes del grupo.

Requisitos de aprobación:

Para aprobar la cursada los alumnos deberán obtener en la entrega final del trabajo práctico una calificación final igual o superior a cuatro (4) puntos en una escala de cero (0) a diez (10), donde cero (0) es la calificación más baja y diez (10) la más alta.

Para aprobar el examen escrito los alumnos deberán obtener una calificación igual o superior a cuatro (4) puntos en una escala de cero (0) a diez (10), donde cero (0) es la calificación más baja y diez (10) la más alta.

Se requiere una asistencia mínima del 75% a los encuentros sincrónicos.

➤ Bibliografía obligatoria:

N°	Descripción
1	Jurafsky, D. y Martin, J. (2000) Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics and Speech Recognition. Prentice Hall
2	Grimmer, J. (2022) Text as Data: A New Framework for Machine Learning and the Social Sciences. Princeton University Press

➤ Bibliografía complementaria:

N°	Descripción
----	-------------

1	Roberts, R. S. (1997) Text Analysis for the Social Sciences. Routledge
2	Tunstall, L., von Werra, L., y Wolf, T. (2022). Natural language processing with transformers. O'Reilly Media, Inc.
3	Zhang, A., Lipton, Z. C., Li, M., y Smola, A. J. (2021). Dive into deep learning.
4	
5	
6	
7	
8	