

Materia: Análisis Predictivo Avanzado	Código: 82.20
Créditos: 3	Carga horaria total: 51
Departamento: Economía, Sociedad y Negocios	Año: 2025
Carrera de: Licenciatura en Analítica Empresarial y Social	
Fecha última actualización: 28/11/2025 17:34:42	

➤ Carga horaria:

51	Horas totales
26	hs. teóricas
25	hs. prácticas
	hs. de laboratorio

3	Horas semanales
3	hs. presencial
	hs. a distancia

➤ Contenidos mínimos:

Tratamiento avanzado de variables categóricas: label encoding, frequency encoding, target encoding.

➤ Presentación de la materia:

La materia se plantea como una continuación de la materia “Análisis Predictivo”. Tomando como base el conocimiento del estudiante del ciclo de trabajo de la ciencia de datos, y los algoritmos más importantes de aprendizaje supervisado y no supervisado, se explican técnicas avanzadas para el tratamiento de variables categóricas, el tratamiento de datasets desbalanceados y técnicas avanzadas de optimización de hiperparámetros.

Por otro lado, se explicarán métricas avanzadas para caracterizar y evaluar modelos, a partir de los shap values y métricas muy utilizadas más allá de las tradicionales precision, recall y AUC.

En la segunda parte de la materia se verán conceptos importantes de series de tiempo (ST) y sistemas de recomendación (RS). Se darán, por otro lado, nociones de redes neuronales y computer vision. Finalmente, se demostrará como hacer deploy de modelos productivos a partir de librerías como Flask y Streamlit, para poder ser consumidos mediante APIs.

➤ Objetivos de aprendizaje:

Se espera que en esta materia los alumnos logren:

- Comprender los distintos tipos de datasets y tratamientos
- Analizar en profundidad los resultados de los algoritmos
- Manejar las últimas técnicas de Machine Learning
- Comprender los modelos de series de tiempo
- Comprender los fundamentos de los sistemas de recomendación
- Obtener nociones de redes neuronales y computer vision

> Contenidos:

Título	Descripción
Unidad 1	Tratamiento avanzado de variables categóricas: label encoding, frequency encoding, target encoding.
Unidad 2	Datasets desbalanceados. Over-sampling, up-sampling, SMOTE
Unidad 3	Optimización de hiperparámetros avanzada. Combinación de grid-search y random-search con pipelines. Optimización bayesiana
Unidad 4	Feature importance avanzada de modelos con Shap values. Métricas avanzadas para evaluación de modelos: lift, gain, KS, curva PR, índice Kappa. Función de ganancia.
Unidad 5	Introducción a series de tiempo. Descomposición de una ST. Series estacionarias y no estacionarias. Diferenciación de STs. Test ADF. Autocorrelación. Modelos predictivos: random walk, tendencia lineal y cuadrática, media, media móvil, Single Exponential Smoothing, ARIMA y variantes, FB Prophet.
Unidad 6	Sistemas de recomendación (RS). Tipos de RS: sistemas basados en contenidos, filtros colaborativos y sistemas híbridos. Librerías Surprise y LightFM. Métricas para la evaluación de RS.
Unidad 7	Introducción de redes neuronales: características y estructura básica de redes convolucionales (CNNs). Introducción a redes aplicadas a computer visión. Librería Keras.
Unidad 7	APIs y deploy de modelos con Streamlit y Flask.

➤ Estrategias de enseñanza:

Las principales dinámicas utilizadas en las clases serán clases teórico prácticas, exposición del docente con instancias de participación de los alumnos, trabajo en pequeños grupos, resolución de problemas, casos, aprendizaje basado en proyectos. Se utilizará el recurso de las encuestas (por parte del ayudante), para ir validando la comprensión de los conceptos a lo largo de la clase. Además, se realizan trabajos prácticos en pequeños grupos.

➤ Actividades:

Título	Descripción
Preguntas a resolver durante la clase	Preguntas con la modalidad "encuesta" de class, para verificar que los alumnos comprendan conceptos clave expuestos en clase
TPs grupales	Dos TPs grupales para que los alumnos pongan en práctica los contenidos vertidos en la materia
Ejercicios clase a clase	La mayoría de las clases cuentan con ejercicios de práctica a resolver para la clase siguiente. La resolución se revisa al principio de la clase siguiente.

➤ Recursos didácticos:

En el aula virtual (campus) se pondrán a disposición los materiales de lectura (bibliografía, artículos, conferencias, videos, etc.), se habilitarán espacios donde cada alumno deberá subir sus TPs (entre otras acciones), etc.

En los encuentros presenciales se trabajará con pizarrón y proyector. Se utilizarán las siguientes herramientas:

- Google Colaboratory
- Jupyter Notebooks (Python)

➤ Modalidad de evaluación y aprobación:

Modalidad de evaluación:

A lo largo de la materia la evaluación de los alumnos abarcará la participación y el debate. A su vez se procurará que el alumno investigue y procure a clase datos, información, dudas, etc. que pudiesen contribuir con sus pares y el tema en general. Asimismo, se evaluará la elaboración de 2 (dos) Trabajos Prácticos Individuales (uno intermedio y otro final) para que los alumnos puedan demostrar la apropiación de herramientas teóricas trabajadas en clase.

La entrega de los TPs se realizará vía campus en fechas estipuladas (o se entregará en mano al docente indicado) con debate y devolución en clase.

Requisitos de aprobación:

- Aprobar los trabajos prácticos (TP1 + TP2) en función de los criterios mínimos descriptos y comunicados en el campus, con una nota mínima de 4 (cuatro) puntos.
- Contar con un porcentaje de asistencia para mantener la regularidad, que es de 75%.
- Se considerará positivamente la participación activa en clase, y la elaboración de las actividades propuestas como ejercicios.

➤ Bibliografía obligatoria:

N°	Descripción
1	Brownlee, J. (2018). How to Use ROC Curves and Precision-Recall Curves for Classification in Python. URL: https://machinelearningmastery.com/roc-curves-and-precision-recall-curves-for-classification-in-python/
2	Brownlee, J. (2019). How to Implement Bayesian Optimization from Scratch in Python.
3	Chawla, N. V., Bowyer, K. W., Hall, L. O., Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal Of Artificial Intelligence Research, Vol 16, pag 321-357.
4	Kuo, C. (2019) Explain Your Model with the SHAP Values.
5	Palachy, S. (2019) Stationarity in time series analysis.
6	Ye, A. (2020). The Beauty of Bayesian Optimization, Explained in Simple Terms.

➤ Bibliografía complementaria:

N°	Descripción

1	Martin-Alarcon, D. (2019). The GeoPandas Cookbook.
2	Mitsa, T. (2010). Temporal Data Mining. Data Mining and Knowledge Discovery Series, Chapman & Hall/CRC Press.
3	Véliz, F. (2020). Ciclos de crecimiento económico.
4	Véliz, F. (2021). Modelo predictivo de puntajes de Lengua y Matemática. Evaluación Aprender 2018.