

Materia: Inteligencia Artificial Generativa	Código: 82.22
Créditos: 1	Carga horaria total: 17
Departamento: Economía, Sociedad y Negocios	Año: 2025
Carrera de: Licenciatura en Analítica Empresarial y Social / Licenciatura en Negocios / Lic.en Administración y Sistemas	
Fecha última actualización: 28/11/2025 11:34:56	

➤ Carga horaria:

17	Horas totales
11	hs. teóricas
6	hs. prácticas
	hs. de laboratorio

1	Horas semanales
1	hs. presencial
0	hs. a distancia

➤ Contenidos mínimos:

Introducción a la IA Generativa y Principios Fundamentales
Ingeniería de Prompts y Arquitecturas de Soluciones de IA Generativa
Arquitecturas de Generación Mejorada con Recuperación (RAG) e Implementación

➤ Presentación de la materia:

En los recientes años, hemos observado cómo la digitalización ha catalizado una transformación total de los modelos de negocio en todas las industrias, dando inicio a una transición hacia un modelo "as a Service". Esta evolución ha promovido un incremento de usuarios digitales y una aceleración en la adquisición de clientes para estas empresas.

Paralelamente, junto con el aumento de dispositivos conectados a internet, hemos presenciado un crecimiento exponencial de datos e información transaccionada digitalmente.

Actualmente, todas las empresas están recolectando datos, ya sea sobre hábitos de compra, datos demográficos o resultados de tratamientos médicos. Sin embargo, la recolección de datos es solo el primer paso. Ahora, las empresas deben empezar a utilizar estos datos para impulsar todas las áreas de su negocio. Un pilar fundamental para lograr esto es la IA Generativa, que permite no solo analizar datos históricos, sino también generar nuevos datos para simulaciones y toma de decisiones basada en datos. Esta materia explorará los principios, técnicas y aplicaciones de la IA Generativa, preparando a los estudiantes para aprovechar el poder de los datos y la IA en la evolución digital en curso.

> Objetivos de aprendizaje:

Explorar el mundo de la IA Gen,
 Analizar datos existentes para generar nuevos datos inexistentes.
 Descubrir como simular situaciones, comportamientos y fenómenos para proporcionar insights valiosos para empresas y proyectos.
 Utilizar herramientas avanzadas y lenguajes de programación relevantes,
 Aprender a crear modelos generativos capaces de generar contenido innovador, desde textos hasta imágenes.
 Trabajar en casos prácticos reales donde la IA Generativa ha impulsado la toma de decisiones y ha catalizado proyectos futuros.
 Comprender habilidades prácticas en IA Generativa que preparen al alumnos para liderar proyectos innovadores e

> Contenidos:

Título	Descripción
Tema 1	Introducción a la IA Gen. LLM. Lenguaje. Imágenes. Multmodal. Modelos Fundacionales. Deep Learning y Machine Learning. Modelos Generativos.
Tema 2	Prompt Engineering
Tema 3	ChatBot
Tema 4	Generación aumentada para modelos del lenguaje

➤ Estrategias de enseñanza:

En la asignatura se combinan clases teóricas con lecturas y trabajos prácticos que los estudiantes realizarán durante la cursada, relacionando los principales contenidos de la materia como la Inteligencia Artificial, la Ingeniería de prompt y la configuración de un chatbot.

➤ Actividades:

Título	Descripción
Redacción de un prompt	Trabajo sobre la Ingeniería de prompts para redactar sus propios prompts
Creación de un chatbot	
Desarrollo de un proyecto	A partir del proyecto, se desarrolla un video y se documenta todo el proyecto para su posterior entrega.

➤ Recursos didácticos:

En los encuentros híbridos se trabajará conectados a Campus y se utilizarán los siguientes software:

Python

IDEs de mercado y según preferencia de los alumnos

Servicios cloud variados

Librerías y frameworks de mercado utilizados para generar soluciones de IA Generativa

En el aula virtual (campus) se pondrán a disposición los materiales de lectura (bibliografía, artículos, conferencias, videos, etc.), se habilitarán espacios donde cada alumno deberá subir sus TPs (entre otras acciones), etc.

➤ Modalidad de evaluación y aprobación:

Modalidad de evaluación:

Por un lado, se evaluará la participación de los alumnos en las actividades propuestas. Se espera que interactúen en forma activa y comprometidamente con el/la docente y sus compañeros, y que cumplan con las tareas en tiempo y forma.

Asimismo, se evaluará la elaboración de un Trabajo Práctico Final para que los alumnos puedan demostrar la apropiación de herramientas teóricas trabajadas en clase.

La entrega del TP se realizará vía campus en fechas estipuladas (o se entregará en mano al docente indicado). Con posterioridad, los alumnos recibirán una devolución escrita individual o grupal acerca de su desempeño.

El trabajo final deberá definir un problema, diseñar una solución, implementar la solución, demostrar la funcionalidad y documentar el proceso.

Requisitos de aprobación:

80% de Asistencia para aprobar la cursada y aprobar con un mínimo de 4 (cuatro) el trabajo práctico final.

➤ Bibliografía obligatoria:

N°	Descripción
1	Retrieval-Augmented Generation for Large Language Models: A Survey Yunfan Gao^a, Yun Xiong^b, Xinyu Gao^b, Kangxiang Jia^b, Jinliu Pan^b, Yuxi Bi^c, Yi Daia, Jiawei Suna, Meng Wang^c, and Haofen Wang^{a,c} ^aShanghai Research Institute for Intelligent Autonomous Systems, Tongji University ^bShanghai Key Laboratory of Data Science, School of Computer Science, Fudan University ^cCollege of Design and Innovation, Tongji University Abstract—Large Language Models (LLMs) showcase impressive capabilities but encounter challenges like hallucination, outdated knowledge, and non-transparent, untraceable reasoning processes. Retrieval-Augmented Generation (RAG) has emerged as a promising solution by incorporating knowledge from external databases. This enhances the accuracy and credibility of the generation, particularly for knowledge-intensive tasks, and allows for continuous knowledge updates and integration of domain-specific information. RAG synergistically merges LLMs' intrinsic knowledge with the vast, dynamic repositories of external databases. This comprehensive review paper offers a detailed examination of the progression of RAG paradigms, encompassing the Naive RAG, the Advanced RAG, and the Modular RAG. It meticulously scrutinizes the tripartite foundation of RAG frameworks, which includes the retrieval, the generation and the augmentation techniques. The paper highlights the state-of-the-art technologies embedded in each of these critical components, providing a profound understanding of the advancements in RAG systems. Furthermore, this paper introduces up-to-date evaluation framework and benchmark. At the end, this article delineates the challenges currently faced and points out prospective avenues for research and development 1. Index Terms—Large language model, retrieval-augmented generation, natural language processing, information retrieval I. INTRODUCTION LARGE language models (LLMs) have achieved remarkable success, though they still face significant limitations, especially in domain-specific or knowledge-intensive tasks [1],

notably producing “hallucinations” [2] when handling queries beyond their training data or requiring current information. To overcome challenges, Retrieval-Augmented Generation (RAG) enhances LLMs by retrieving relevant document chunks from external knowledge base through semantic similarity calculation. By referencing external knowledge, RAG effectively reduces the problem of generating factually incorrect content. Its integration into LLMs has resulted in widespread adoption, establishing RAG as a key technology in advancing chatbots and enhancing the suitability of LLMs for real-world applications.

RAG technology has rapidly developed in recent years, and the technology tree summarizing related research is shown in Figure 1. The development trajectory of RAG in the era of large models exhibits several distinct stage characteristics. Initially, RAG’s inception coincided with the rise of the Transformer architecture, focusing on enhancing language models by incorporating additional knowledge through Pre-Training Models (PTM). This early stage was characterized by foundational work aimed at refining pre-training techniques [3]–[5]. The subsequent arrival of ChatGPT [6] marked a pivotal moment, with LLM demonstrating powerful in context learning (ICL) capabilities. RAG research shifted towards providing better information for LLMs to answer more complex and knowledge-intensive tasks during the inference stage, leading to rapid development in RAG studies. As research progressed, the enhancement of RAG was no longer limited to the inference stage but began to incorporate more with LLM fine-tuning techniques.

The burgeoning field of RAG has experienced swift growth, yet it has not been accompanied by a systematic synthesis that could clarify its broader trajectory. This survey endeavors to fill this gap by mapping out the RAG process and charting its evolution and anticipated future paths, with a focus on the integration of RAG within LLMs. This paper considers both technical paradigms and research methods, summarizing three main research paradigms from over 100 RAG studies, and analyzing key technologies in the core stages of “Retrieval,” “Generation,” and “Augmentation.” On the other hand, current research tends to focus more on methods, lacking analysis and summarization of how to evaluate RAG. This paper comprehensively reviews the downstream tasks, datasets, benchmarks, and evaluation methods applicable to RAG. Overall, this paper sets out to meticulously compile and categorize the foundational technical concepts, historical progression, and the spectrum of RAG methodologies and applications that have emerged post-LLMs. It is designed to equip readers and professionals with a detailed and structured understanding of both large models and RAG. It aims to illuminate the evolution

The burgeoning field of RAG has experienced swift growth, yet it has not been accompanied by a systematic synthesis that could clarify its broader trajectory. This survey endeavors to fill this gap by mapping out the RAG process and charting its evolution and anticipated future paths, with a focus on the integration of RAG within LLMs. This paper considers both technical paradigms and research methods, summarizing three main research paradigms from over 100 RAG studies, and analyzing key technologies in the core stages of “Retrieval,” “Generation,” and “Augmentation.” On the other hand, current research tends to focus more on methods, lacking analysis and summarization of how to evaluate RAG. This paper comprehensively reviews the downstream tasks, datasets, benchmarks, and evaluation methods applicable to RAG. Overall, this paper sets out to meticulously compile and categorize the foundational technical concepts, historical progression, and the spectrum of RAG methodologies and applications that have emerged post-LLMs. It is designed to equip readers and professionals with a detailed and structured understanding of both large models and RAG. It aims to illuminate the evolution

	of retrieval augmentation techniques, assess the strengths and weaknesses of various approaches in their respective contexts, and speculate on upcoming trends and innovations. Our contributions are as follows: • In this survey, we present a thorough and systematic review of the state-of-the-art RAG methods, delineating its evolution through paradigms including naive RAG, arXiv:2312.10997v5 [cs.CL] 27 Mar 2024
2	Embracing Gen AI DECEMBER 2023 The art of the possible Copyright © 2023 by Boston Consulting Group. All rights reserve
3	
4	
5	
6	

➤ Bibliografía complementaria:

N°	Descripción
1	
2	
3	
4	
5	
6	