

Materia: Analítica de Big Data con Spark	Código: 82.81
Créditos: 3	Carga horaria total: 51
Departamento: Economía, Sociedad y Negocios	Año: 2025
Carrera de: Licenciatura en Analítica Empresarial y Social	
Fecha última actualización: 28/11/2025 12:22:32	

➤ Carga horaria:

51	Horas totales
31	hs. teóricas
20	hs. prácticas
0	hs. de laboratorio

3	Horas semanales
3	hs. presencial
	hs. a distancia

➤ Contenidos mínimos:

Introducción al Spark para Data Analytics. Apache Spark y Big Data. Fundamentos de programación en Spark. Procesamiento de datos con PySpark I**.Procesamiento de datos con PySpark II. Análisis de datos exploratorios con PySpark. Aprendizaje no supervisado con Spark. Detección de anomalías y visualización de datos geoespaciales. Aprendizaje automático distribuido con Spark MLlib. Aprendizaje automático distribuido con Spark MLlib. Optimización de rendimiento en PySpark. Procesamiento de datos en tiempo real con Spark. Análisis de texto con PySpark. .Procesamiento de grafos con PySpark GraphFrames. Análisis de texto con PySpark. Casos de uso en análisis de datos de gran escala.

➤ Presentación de la materia:

Apache Spark es una plataforma para el procesamiento de Big Data que brinda la capacidad de procesar una gran cantidad de datos de escala. Es un motor de análisis de datos para el procesamiento de Big data, que tiene modelos integrados para SQL, aprendizaje automático, aprendizaje profundo y procesamiento de grafos. PySpark es un motor de cómputo distribuido de propósito general que combina Python con el poder de Apache Spark

El propósito es que los alumnos aprendan los conceptos básicos de esta tecnología y adquiere experiencia teorico-práctica utilizando Spark para el analisis de datos. Esta materia provee a los alumnos las herramientas y conocimientos para que puedan desarrollarse en disciplinas de ingeniería de datos, analytics o machine learning.

> Objetivos de aprendizaje:

Los alumnos lograran adquirir los conocimientos para comprender la arquitectura de Spark y poder aplicar los conocimientos adquiridos en casos de uso reales de analítica de datos de gran escala, como análisis de registros de aplicaciones, procesamiento de datos en tiempo real y análisis de redes sociales.

Al finalizar el curso los alumnos deberán:

Comprender la arquitectura de Spark y conocer sus componentes principales.

Procesar y manipular datos con spark utilizando transformaciones y operaciones avanzadas.

Procesar datos estructurados con SparkSQL y datos en tiempo real.

Aplicar técnicas de Machine Learning distribuido para construir modelos de clasificación, regresión y agrupamiento.

Procesar y analizar grafos para realizar operaciones como búsqueda de caminos, análisis de comunidades y conexión de componentes.

Comprender cómo optimizar el rendimiento de las aplicaciones de Spark y gestionar los recursos.

Aplicar los conocimientos adquiridos en casos de uso reales de analítica de datos de gran escala.

> Contenidos:

Título	Descripción
Introducción a Apache Spark y Big Data	• Avances en el procesamiento a gran escala • Map Reduce y HDFS • Arquitectura de Spark
Fundamentos de programación en Spark	Introducción a Python como lenguaje de programación en PySpark. • Manipulación de RDDs (Resilient Distributed Datasets) en PySpark. • Transformaciones y acciones básicas en PySpark.
Procesamiento de datos con PySpark I**	Carga y almacenamiento de datos en PySpark. • Dataframes y procesamiento de datos con SQL • Operaciones de manipulación de datos en DataFrames.
Procesamiento de datos con PySpark II	Operaciones de manipulación de datos en DataFrames. • Filtros, agregaciones y Window Functions • UDF: User Defined Functions
Análisis de datos exploratorio con PySpark	• Herramientas y técnicas para el análisis exploratorio de datos en PySpark. • Visualización de datos utilizando Spark. • Limpieza y transformación de datos para análisis.
Aprendizaje no supervisado con Spark	• Reducción de dimensionalidad • Construcción de modelos de clustering utilizando Spark MLlib

Aprendizaje automático distribuido con Spark MLlib	Introducción al aprendizaje automático y su aplicación en PySpark. • Construcción de modelos de clasificación y regresión utilizando Spark MLlib. • Validación de modelos y evaluación de su rendimiento.
Aprendizaje automático distribuido con Spark MLlib	• Construcción de Pipelines de Machine Learning • Machine Learning Operation • Serving model
Optimización de rendimiento en PySpark	• Estrategias para optimizar el rendimiento de las aplicaciones de PySpark. • Gestión de la memoria y persistencia en caché. • Ajuste de configuraciones y parámetros de PySpark para un mejor rendimiento.
Procesamiento de datos en tiempo real con Spark	• Conceptos básicos de procesamiento en tiempo real. • Uso de Spark Streaming para procesar flujos de datos en tiempo real. • Ventanas de tiempo y operaciones de agregación en Spark Streaming.
Análisis de texto con PySpark	• Procesamiento y análisis de texto utilizando técnicas de NLP (Procesamiento del Lenguaje Natural) en PySpark. • Extracción de características de texto y modelado de temas utilizando LLM en PySpark. • Análisis de sentimientos, clasificación y generación de texto en PySpark

➤ Estrategias de enseñanza:

Este curso se imparte de forma presencial híbrida con clases sincrónicas y mediante módulos de capacitación digital que los estudiantes pueden completar por su cuenta

➤ Actividades:

Título	Descripción

➤ Recursos didácticos:

En las clases sincrónicas se trabajará con material en diapositivas donde se expondrán los conceptos teóricos. Para los laboratorios se trabajará con plataformas virtuales donde se pueden preparar y resolver los mismos.

Por otra parte, en el aula virtual (campus) se pondrán a disposición los siguientes materiales:

- Actividades de clases y demostraciones
- Ejercicios de laboratorio
- Artículos, conferencias y videos relevantes
- Soluciones de ejemplo

➤ Modalidad de evaluación y aprobación:

Modalidad de evaluación:

Son requisitos de aprobación del curso:

Aprobar los trabajos prácticos con una nota superior a 4 (cuatro) en función de los criterios mínimos descritos y comunicados en el campus.

¿Cómo se calcula la nota de cursada?

La nota de cursada final se obtendrá de la siguiente manera:

(TP1 0,1 + TP2 0,1 + TP3 0,4 + TP4 0,4).

¿Cómo se redondea la nota de cursada?

La nota correspondiente a la cursada será redondeada según el siguiente criterio:

Si la parte decimal es menor o igual que 0,25, se pasa al entero inmediatamente inferior.

Si la parte decimal está comprendida entre 0,26 y 0,75, se deja como 0,50.

Si es mayor a 0,75, la nota se lleva al entero superior más cercano.

Requisitos de aprobación:

Se evaluará la participación de los alumnos en las actividades propuestas. Se espera que interactúen en forma activa y comprometidamente con el/la docente y sus compañeros, y que cumplan con las tareas en tiempo y forma. Además, los alumnos deben relaborar cuatro Trabajos Prácticos para que los alumnos puedan demostrar la apropiación de herramientas teóricas trabajadas en clase.

La entrega de los TPs se realizará vía campus en fechas estipuladas. Con posterioridad, los alumnos recibirán una devolución individual o grupal acerca de su desempeño.

➤ **Bibliografía obligatoria:**

N°	Descripción
1	Bill Chambers, Matei Zaharia (2018). Spark: The Definitive Guide
2	Jules Damji, Brooke Wenig, Tathagata Das, Denny Lee. Learning Spark: LightningFast Data Analytics
3	Sandy Ryza, Uri Laserson, Sean Owen, Josh Wills (2015). Advanced Analytics with Spark
4	
5	
6	

➤ **Bibliografía complementaria:**

N°	Descripción
1	Pyspark Documentation. PySpark Overview -
2	Spark Documentation Spark Overview
3	
4	
5	
6	