

Streaming de Video On-Demand

Scalability + Performance + Cost — CDN multi-vendor, ABR, off-line precompute (Kallen)

Ingeniería de Software II · ITBA · 2026-1C · Caso mock del wiki

RESUMEN

Simulacro de parcial: OTT regional, 4M suscriptores, pico de 600k streams concurrentes, catálogo de ~500 TB. La columna vertebral es Kallen: *Partition + Replicate + Index, off-line precompute* y *memory hierarchy*. ABR + edge caching definen la economía; las recomendaciones son el diferenciador, pero con fallback. Caso *sintético* (source: mock-streaming-video.md).

§1 Enunciado (resumen)

Compañía de medios latinoamericana lanza su propio OTT (Over-The-Top) cubriendo Argentina, Chile, Uruguay, Paraguay y Bolivia. Capitaliza su catálogo histórico (~15.000 títulos) y suma producción original (source: mock-streaming-video.md).

- **Target:** 4M suscriptores en 24 meses.
- **Pico:** 600k streams concurrentes viernes/sábado noche (prime 20–24 hs).
- **Bitrate:** 3 Mbps (SD) a 25 Mbps (4K HDR); catálogo ~500 TB tras transcoding multi-bitrate.
- **Derechos:** ventanas temporales (un título 6 meses) y geográficas (a veces solo AR, a veces toda la región).
- **Restricciones:** 6 squads, presupuesto de CDN ajustado, deadline político (lanzar antes de un evento deportivo regional).

CUÁNDO NO · CUIDADO

Trampa de contexto: asumir que un día con evento deportivo es "igual que otro día". Es 10× — el dimensionamiento se hace sobre el pico, no sobre la media (source: mock-streaming-video.md).

§2 Stakeholders

- Suscriptores finales (familias, gamers, fans deportivos)
- Equipo de contenido / programación
- Equipo legal de derechos (ventanas geo y temporales)
- Marketing y crecimiento (churn prevention)
- Recomendaciones / data science
- Producción original
- Operadores de CDN (Akamai, Cloudflare, Fastly, ISPs)
- Anunciantes (si el modelo es AVOD/híbrido)
- Pagos y suscripciones
- Operaciones / SRE

§3 Atributos de calidad priorizados

SCALABILITY

PERFORMANCE

AVAILABILITY

SECURITY

AUDITABILITY

1. Scalability

Picos 5× sobre carga media; escalado horizontal masivo en CDN.

2. Performance

Startup latency < 2 s; rebuffering < 1% del tiempo de stream.

3. Availability

99.95% en horario prime (20–24 hs).

4. Security

Protección de contenido (DRM), prevención de cuenta compartida, datos de pago.

5. Auditability

Derechos por país y ventana temporal exigen trazabilidad de qué se sirvió a quién.

CUÁNDO NO • CUIDADO

Error que mata la respuesta: listar *personalization* como atributo de calidad (es una funcionalidad) o *cost-efficiency* como QA (es un constraint de negocio). La *compliance regional* se subsume en *Auditability* y *Security* (source: mock-streaming-video.md; ver [[Atributos de Calidad — tabla ISO 25000 (cátedra)]]).

§4 Escenarios cuantificados

TABLA 1. Árbol de utilidad — escenarios medibles

Atributo	Estímulo	Respuesta / medida
Scalability	Viernes 22 hs + evento deportivo	Sostener 600k streams concurrentes (5× media) sin degradar
Performance	Usuario da play	Startup latency < 2 s
Performance	Durante el stream	Rebuffering < 1% del tiempo total
Performance	Carga del home	Recomendaciones servidas en < 50 ms
Availability	Horario prime 20–24 hs	Disponibilidad ≥ 99.95%
Security	Reproducción de título con DRM	Key rotation + device limits activos; sin DRM no hay contrato

§5 Diagrama de componentes




FIGURA 1. Tres planos desacoplados: playback path sirve bytes por CDN jerárquica (edge→regional→origin→hot), el control plane resuelve catálogo+derechos+recos+DRM, y los eventos alimentan vía Kafka el feature store. El transcoding off-line prepara el hot tier; los masters viven en cold.

El playback path (servir bytes de video) está físicamente separado del control plane (catálogo, derechos, recos). Acoplarlos es el anti-patrón canónico: cuando uno cae, cae todo.

§6 Decisiones arquitectónicas + rationale

TABLA 2. Decisiones curadas

Decisión	Rationale
CDN multi-vendor con origin shielding y caching jerárquico (edge → regional → origin)	95% del tráfico desde edge cercano; un solo CDN es SPOF y trampa de pricing. [[Principio de localidad]] espacial.
Transcoding asincrónico multi-bitrate (ABR — HLS/DASH)	Cada cliente elige bitrate según su ancho de banda; reduce rebuffering. Off-line: transcodear al entrar al catálogo, no por request.
Catálogo + derechos materializados por país-perfil cada hora, separados del playback	Reads >>> writes y la query es bounded ("qué puede ver este usuario hoy"). Patrón Kallen/Twitter.
Recomendaciones online: feature store KV (Redis) + modelo GPU, con fallback top-N por país	Latencia < 50 ms en home; si el modelo falla, top-N alcanza y la home no queda vacía. Defense in depth contra ML downtime.
Event sourcing del comportamiento (play/pause/seek/abandono) en Kafka → data lake → batch	Los eventos son source of truth, no la base operacional.
DRM (Widevine/PlayReady/FairPlay) con key rotation y device limits	Sin DRM no hay contrato con los estudios mayores.
Cold tier (S3 Glacier) para masters; hot tier solo bitrates servibles	Master de 100 GB no se sirve nunca — guardarlo en hot es quemar plata. [[Memory hierarchy]].

§7 Principios de Kallen aplicados

DEFINICIÓN

Partition · Replicate · Index: los tres movimientos para comprar Scalability.

Partition (sharding) reparte la carga; **Replicate** sirve reads desde copias cercanas (edge caching multi-CDN); **Index** evita scans (catálogo materializado por país-perfil). No hay magia ni shortcut (source: mock-streaming-video.md; ver [[Partition, Replicate, Index]]).

DEFINICIÓN

Off-line vs Online computation: precomputar cuando reads >>> writes y la query es bounded. Acá: transcodear al ingreso del título (no por request) y materializar el catálogo por país cada hora (no por click) (source: mock-streaming-video.md; ver [[Off-line vs Online computation]]).

DEFINICIÓN

Memory hierarchy: ubicar cada dato en el tier que su patrón de acceso justifica. Masters en **cold** (Glacier), bitrates servibles en **hot**, contenido caliente en el **edge** cerca del usuario (source: mock-streaming-video.md; ver [[Memory hierarchy]]).

EJEMPLO

Lo mismo que Twitter: el catálogo materializado por país-perfil es el *timeline precomputado* de [[Caso Twitter — Big Data en tiempo real|Twitter]] aplicado a otro dominio. Reads dominantes + query bounded $\Rightarrow$ precompute. Verifica que el alumno generaliza el principio, no lo memoriza por dominio (source: mock-streaming-video.md).

§8 Trade-offs explícitos

TRADE-OFF

Scalability/Availability $\leftrightarrow$ Cost: multi-CDN paga sobre-aprovisionamiento y duplica integraciones, pero elimina el SPOF y da palanca de negociación. Con presupuesto ajustado, multi-CDN no es paranoia: single-CDN te deja sin salida cuando el contrato sube 80% (source: mock-streaming-video.md).

TRADE-OFF

Performance $\leftrightarrow$ Freshness: catálogo materializado da queries rápidas pero el refresh horario tolera hasta 1 h de desactualización. Aceptable: los derechos no cambian por minuto.

TRADE-OFF

Performance/Quality $\leftrightarrow$ Availability (recos): el modelo GPU recomienda mejor pero puede caer. El fallback top-N degrada la calidad de la reco pero mantiene la home viva. Recomendar bien con fallback > recomendar perfecto sin fallback.

TRADE-OFF

Cold $\leftrightarrow$ Hot tier: Glacier es barato pero lento de recuperar; sirve solo para masters que nunca van al usuario. Los bitrates servibles deben estar en hot/edge sí o sí.

§9 Trampas y anti-patrones

CUÁNDO NO · CUIDADO

- **Single-CDN:** cuando el contrato sube 80%, no podés migrar en 6 meses.
- **Transcodear on-demand:** el primer viewer paga la cuenta de CPU de los siguientes.
- **Materializar el catálogo en cada request:** 1 query por click = death by latency.
- **Recos acopladas al motor de playback:** cuando ML cae, todo cae.
- **DRM como afterthought:** los estudios cancelan contratos sin DRM operativo.
- **Servir master files al edge:** pagás por GB lo que no usa nadie.
- **Asumir día normal en evento deportivo:** es 10×.

(source: mock-streaming-video.md)

REGLA DE ORO

Mantra del caso: ABR + edge caching son el par canónico que define la economía del streaming; los derechos son parte del **modelo de dominio**, no un detalle de implementación (source: mock-streaming-video.md).

EN EL PARCIAL

Respuesta aprobada mínima: atributos priorizados con justificación (sin colar funcionalidades como QAs) + 2-3 escenarios cuantificados + diagrama con playback path separado del control plane + los 3 principios de Kallen nombrados y aplicados + 2 trade-offs explícitos. El error que mata: saltar al dibujo de cajas antes de articular los atributos, o tratar las recomendaciones sin fallback.